Intrusion Detection

Erwin Erikson
Faculty of Information Technology
Institut Teknologi Batam
Batam, Indonesia
1822003@student.iteba.ac.id

Muhammad Al Imron
Faculty of Information Technology
Institut Teknologi Batam
Batam, Indonesia
1822007@student.iteba.ac.id

Farhan Ghulam Hadi Saputra
Faculty of Information Technology
Institut Teknologi Batam
Batam, Indonesia
1822014@student.iteba.ac.id

***Abstract*—Meningkatnya perkembangan internet tidak terlepas dari serangan seperti malware infection. Intrusion Detection System (IDS) adalah masalah nonlinier, rumit dan berhubungan dengan data lalu lintas jaringan. IDS mencoba untuk mengidentifikasi dan memberi tahu aktivitas pengguna sebagai anomali normal. Untuk mendeteksi berbagai serangan jaringan dapat dilatih dengan melakukan percobaan menggunakan dataset NSL-KDD dengan beberapa algoritma yaitu Random Forest, K-Neighbors, SVM dan Ensemble Learning.**

***Keywords*—intrusion detection, Random Forest, K-Neighbors, SVM, Ensemble Learning, NSL-KDD dataset.**

I. Pendahuluan

Pengguna internet yang terus meningkat dari tahun ke tahun tidak terlepas dari serangan yang timbul dari teknologi jaringan seperti serangan *malware infection*. Oleh karena itu, diperlukan keamanan dalam sistem komputer untuk mencegah dari serangan.

IDS pertama kali diperkenalkan oleh James Anderson et al. Sistem deteksi intrusi diklasifikasikan menjadi dua jenis yaitu berbasis host dan berbasis jaringan. Sistem deteksi intrusi berbasis host memeriksa data yang dimiliki sistem komputer individu, sedangkan sistem berbasis jaringan menganalisis data yang dipertukarkan antar komputer [1].

Sistem deteksi kesalahan penggunaan menemukan tanda serangan yang dikenal dalam sumber daya yang dipantau. Sistem deteksi anomali menemukan serangan dengan mendeteksi perubahan pola pemanfaatan atau perilaku sistem [5].

Dalam melakukan deteksi serangan, dapat digunakan beberapa algoritma yaitu Random Forest, K-Neighbors [3], SVM dan Ensemble Learning [7]. Dan tujuan dari penelitian ini adalah untuk membandingkan performa dari masing-masing algoritma.

II. Penjelasan Teori

A. Random Forest

Hutan acak (*Random Forest*) adalah kumpulan pohon keputusan yang digunakan untuk meningkatkan akurasi, biasanya dilatih dengan metode "*bagging*". Ide umum dari metode *bagging* adalah bahwa kombinasi model pembelajaran meningkatkan hasil secara keseluruhan.

Keuntungan *Random Forest* adalah sebagai berikut [1]:

1) Hutan yang dihasilkan dapat disimpan untuk referensi di masa mendatang.
2) Hutan acak mengatasi masalah penyesuaian.
3) Dalam akurasi RF dan kepentingan variabel secara otomatis dihasilkan.

Flowchart dari proses pemodelan algoritma *Random Forest* dapat dilihat pada "Gambar. 1".

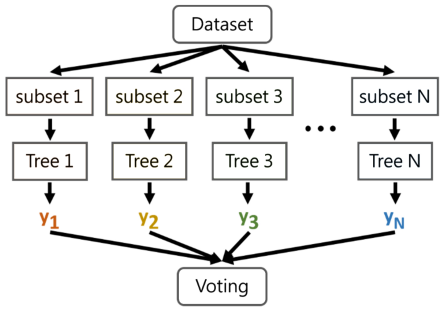

Gambar 1: Flowchart Algoritma Random Forest

B. K-Nearest Neighbors

K-nearest neighbors (knn) adalah algoritma yang berfungsi untuk melakukan klasifikasi suatu data berdasarkan data pembelajaran (*train data sets*), yang diambil dari k tetangga terdekatnya (*nearest neighbors*), dengan k merupakan banyaknya tetangga terdekat [2]. Beberapa formula yang digunakan adalah:

- *Euclidean Distance*
  Untuk mendefinisikan jarak antara dua titik yaitu titik pada data training (x) dan titik pada data testing (y), maka digunakan rumus *Euclidean* [3], yaitu:

$$d(x,y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}$$

  dimana:
  d = jarak antara 2 titik
  x = data uji
  y = data latih
  i = merepresentasikan nilai atribut
  n = merupakan dimensi atribut.

- *City Block Distance*
  City Block Distance umumnya dihitung antara 2 koordinat objek yang berpasangan. Ini adalah penjumlahan dari perbedaan absolut antara 2 koordinat. *City Block*

Distance 2-titik a dan b dengan dimensi k dihitung secara matematis menggunakan rumus berikut ini:

$$d_{ij} = \sum_{i=1}^{k} |a_i - b_i|$$

- *Manhattan Distance*
  Manhattan Distance merupakan salah satu pengukuran yang paling banyak digunakan meliputi penggantian perbedaan kuadrat dengan menjumlahkan perbedaan *absolute* dari variabel-variabel. Fungsi ini hanya akan menjumlahkan selisih nilai x dan y dari dua buah titik.

- *Minkwoski Distance*
  Minkwoski Distance adalah metrik dalam ruang vektor bernorma yang dapat dianggap sebagai generalisasi dari kedua jarak *Euclidean* dan jarak *Manhattan*. Jarak *Minkowski* antara dua variabel X dan Y didefinisikan sebagai:

$$d = (\sum_{i=1}^{n} |X_i - Y_i|^p)^{1/p}$$

  Kasus di mana p = 1 setara dengan jarak *Manhattan* dan kasus di mana p = 2 setara dengan jarak *Euclidean*.

Flowchart dari proses pemodelan algoritma *K-nearest neighbors* dapat dilihat pada "Gambar. 2" [4].

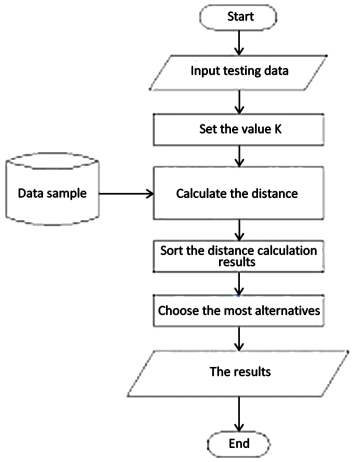

Gambar 2: Flowchart Algoritma K-nearest neighbors

C. SVM

Teori SVM berasal dari statistik dan prinsip dasar SVM adalah menemukan *hyperplane* linier yang optimal dalam ruang fitur yang secara maksimal memisahkan dua kelas target [5].

Dalam kaitannya dengan fungsi kernel, fungsi diskriminan mengambil bentuk berikut:

$$f(x) = \sum_{i}^{n} \alpha_i k(x, x_i) + b$$

Dalam pekerjaan ini, kernel *Gaussian* telah digunakan untuk membangun pengklasifikasi SVM.
Gaussian kernel:

$$K(x_i, x_j) = exp\left(-\frac{||x_i - x_j||^2}{2\sigma}\right)$$

dimana σ adalah lebar fungsi.

Fungsi kernel dan parameternya harus dipilih untuk membangun pengklasifikasi SVM. Melatih SVM menemukan *hyperplane* margin besar, yaitu menetapkan parameter α.

Flowchart dari proses pemodelan algoritma SVM dapat dilihat pada "Gambar. 3" [6].

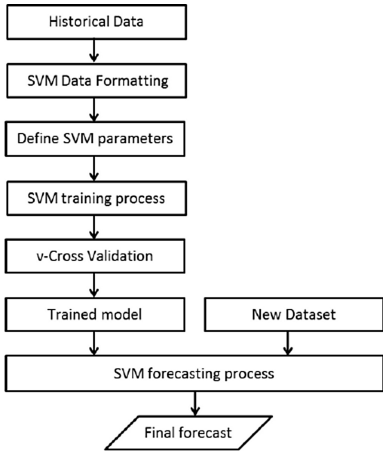

Gambar 3: Flowchart Algoritma SVM

D. Ensemble Learning

Metode ini adalah menggabungkan beberapa fitur dengan pembelajaran *Ensemble*.

Flowchart dari proses pemodelan algoritma *Ensemble Learning* dapat dilihat pada "Gambar. 4" [7].

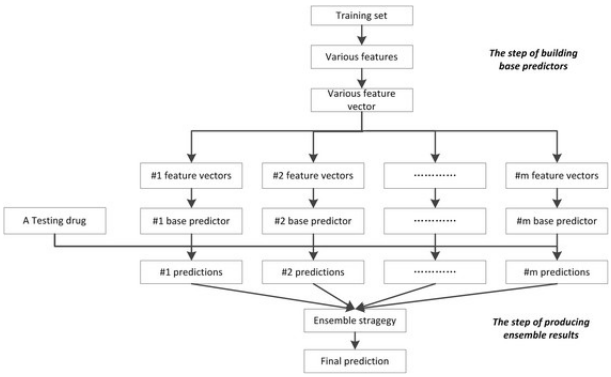

Gambar 4: Flowchart Algoritma Ensemble Learning

III. METODOLOGI

Metodologi adalah tahapan yang akan dilakukan dalam penelitian agar dapat memenuhi tujuan sesuai dengan yang diharapkan.

Sistem deteksi intrusi jaringan dapat menganalisis paket yang ditangkap jaringan dan mendeteksi apakah itu akan menjadi penyusupan atau tidak. Dilihat dari arsitekturnya, diagram sistem mencakup beberapa modul, yang ditunjukkan pada "Gambar. 5".

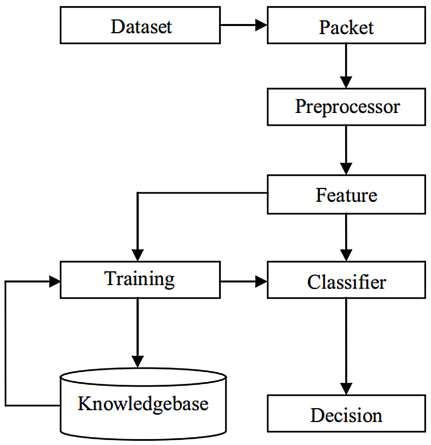

Gambar 5: Blok Diagram Modul Pada Sistem

Berdasarkan gambar di atas, terdapat beberapa modul yang memperkenalkan sistem deteksi intrusi jaringan seperti:

Dataset

Untuk melakukan pelatihan/pengujian digunakan dataset NSL-KDD dimana NSLKDDTrain sebagai data latih dan NSLKDDTest sebagai data uji.

Packet

Paket untuk dijadikan sumber data NIDS yang diambil dari dataset.

Preprocessor

Pada fase preprocessing, lalu lintas jaringan dikumpulkan dan diproses untuk digunakan sebagai input ke sistem.

Feature Extractor

Modul ini mengekstrak vektor fitur dari paket jaringan (catatan koneksi) dan mengirimkan vektor fitur ke modul pengklasifikasi.

Classifier

Fungsi modul ini adalah untuk menganalisis aliran jaringan dan menarik kesimpulan apakah terjadi intrusi atau tidak.

Decision

Modul ini akan mendeteksi intrusi yang terjadi.

Knowledgebase

Modul ini berfungsi untuk sampel pelatihan fase classifier. Sistem dapat bekerja secara efektif hanya jika telah dilatih dengan benar dan memadai. Sampel intrusi dapat disempurnakan di bawah partisipasi pengguna, sehingga kemampuan deteksi dapat terus ditingkatkan.

IV. Hasil dan Pembahasan

Dari dataset yang digunakan, terbagi beberapa kategori serangan yaitu 0 = Normal, 1 = DoS, 2 = Probe, 3 = R2L, 4 = U2R. Hasil pembagian setiap kategori serangan dari data latih dan data uji dapat dilihat pada "Gambar. 6".

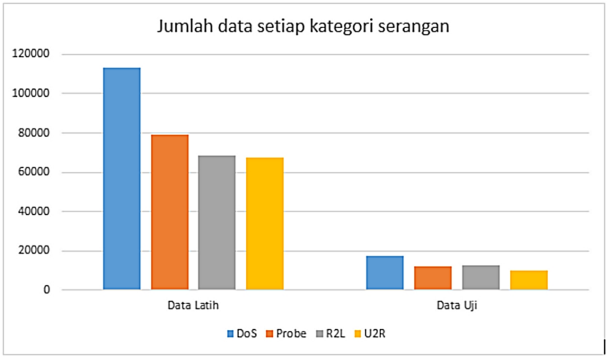

Gambar 6: Jumlah Data Setiap Kategori Serangan

Untuk menghitung precision dan recall dengan cepat dari setiap serangan dilakukan tahap *Prediction* dan *Evaluation* (*validation*) dengan *confusion matrix* seperti pada "Gambar. 7".

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

Gambar 7: Confusion Matrix

Hasil *Prediction* dan *Evaluation* (*validation*) metode *Random Forest* semua fitur dapat dilihat pada "Gambar. 8".

DoS

Predicted attacks	0	1
Actual attacks		
0	9686	25
1	7447	13

Probe

Predicted attacks	0	2
Actual attacks		
0	9364	347
2	1076	1345

R2L

Predicted attacks	0
Actual attacks	
0	9711
3	2885

U2R

Predicted attacks	0
Actual attacks	
0	9711
4	67

Gambar 8: Confusion Matrix Random Forest All Fitur

Hasil *Prediction* dan *Evaluation* (*validation*) metode *Random Forest* 13 fitur dapat dilihat pada "Gambar. 9".

DoS

Predicted attacks	0	1
Actual attacks		
0	9162	549
1	2136	5324

Probe

Predicted attacks	0	2
Actual attacks		
0	9413	298
2	975	1446

R2L

Predicted attacks	0	3
Actual attacks		
0	9693	18
3	2880	5

U2R

Predicted attacks	0	4
Actual attacks		
0	9711	0
4	60	7

Gambar 9: Confusion Matrix Random Forest 13 Fitur

Hasil *Prediction* dan *Evaluation* (*validation*) metode *K-Neighbors* dapat dilihat pada "Gambar. 10".

DoS

Predicted attacks	0	1
Actual attacks		
0	9422	289
1	1573	5887

Probe

Predicted attacks	0	2
Actual attacks		
0	9437	274
2	1272	1149

R2L

Predicted attacks	0	3
Actual attacks		
0	9706	5
3	2883	2

U2R

Predicted attacks	0	4
Actual attacks		
0	9711	0
4	65	2

Gambar 10: Confusion Matrix K-Neighbors

Hasil *Prediction* dan *Evaluation* (*validation*) metode SVM dapat dilihat pada "Gambar. 11".

DoS

Predicted attacks	0	1
Actual attacks		
0	9455	256
1	1359	6101

Probe

Predicted attacks	0	2
Actual attacks		
0	9576	135
2	1285	1136

R2L

Predicted attacks	0	3
Actual attacks		
0	9639	72
3	2737	148

U2R

Predicted attacks	0	4
Actual attacks		
0	9710	1
4	67	0

Gambar 11: Confusion Matrix SVM

Hasil *Prediction* dan *Evaluation* (*validation*) metode *Ensemble Learning* dapat dilihat pada "Gambar. 12".

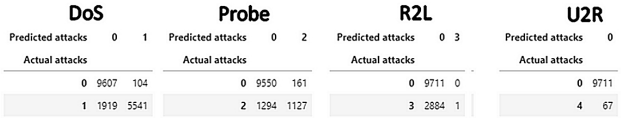

Gambar 12: Confusion Matrix Ensemble Learning

Dengan *confusion matrix* dilakukan penghitungan *Accuracy*, *Precision*, *Recall*, dan *F-measure* dari nilai masing-masing dalam matriks dengan menerapkan persamaan berikut:

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F - measure = 2 * \frac{precision * recall}{precision + recall}$$

dimana:
TP = True Positive
TN = True Negative
FP = False Positive
FN = False Negative

Hasil evaluasi kinerja dari masing-masing model atau algoritma, dapat dilihat pada tabel-tabel berikut:
Pengujian menggunakan algoritma *Random Forest* untuk semua fitur dapat dilihat pada "Tabel. I".

Tabel I: Algoritma Random Forest untuk semua Fitur

	Accuracy	**Precision**	**Recall**	**F-measure**
DoS	0.99796	0.99906	0.99651	0.99765
Probe	0.99670	0.99675	0.99262	0.99469
R2L	0.99775	0.94964	0.82014	0.87775
U2R	0.98047	0.97293	0.96844	0.97290

Pengujian menggunakan algoritma *Random Forest* untuk 13 fitur dapat dilihat pada "Tabel. II".

Tabel II: Algoritma Random Forest untuk 13 Fitur

	Accuracy	**Precision**	**Recall**	**F-measure**
DoS	0.99796	0.99839	0.99651	0.99718
Probe	0.99382	0.98973	0.98668	0.98758
R2L	0.97856	0.97280	0.96525	0.96838
U2R	0.99693	0.96256	0.83183	0.90644

Pengujian menggunakan algoritma *K-Neighbors* dapat dilihat pada "Tabel. III".

Tabel III: Algoritma K-Neighbors

	Accuracy	**Precision**	**Recall**	**F-measure**
DoS	0.99715	0.99678	0.99665	0.99672
Probe	0.99077	0.98606	0.98508	0.98553
R2L	0.96705	0.95265	0.95439	0.95344
U2R	0.99703	0.93143	0.85073	0.87831

Pengujian menggunakan algoritma SVM dapat dilihat pada "Tabel. IV".

Tabel IV: Algoritma SVM

	Accuracy	**Precision**	**Recall**	**F-measure**
DoS	0.99371	0.99107	0.99450	0.99278
Probe	0.98450	0.96907	0.98365	0.97613
R2L	0.96793	0.94854	0.96264	0.95529
U2R	0.99632	0.91056	0.82909	0.84869

Pengujian menggunakan algoritma *Ensemble Learning* dapat dilihat pada "Tabel. V".

Tabel V: Algoritma Ensemble Learning

	Accuracy	**Precision**	**Recall**	**F-measure**
DoS	0.99808	0.99852	0.99718	0.99772
Probe	0.99275	0.98765	0.98953	0.98841
R2L	0.97158	0.95838	0.96409	0.96079
U2R	0.99744	0.94270	0.88758	0.91119

Tingkat akurasi dari masing-masing serangan disajikan dalam bentuk diagram garis seperti pada "Gambar. 13".

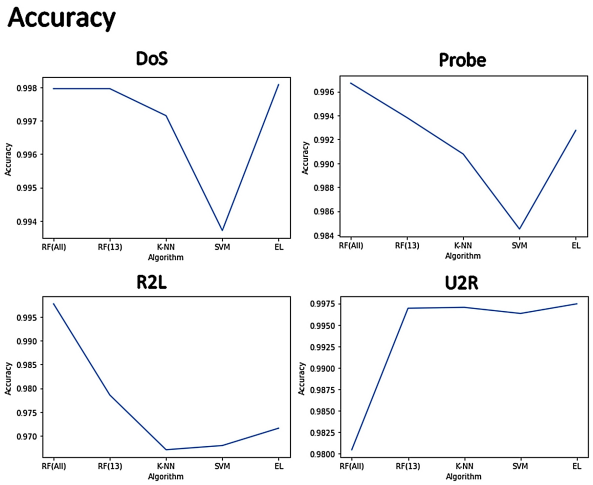

Gambar 13: Tingkat Akurasi masing-masing Serangan

Tingkat presisi dari masing-masing serangan disajikan dalam bentuk diagram garis seperti pada "Gambar. 14".

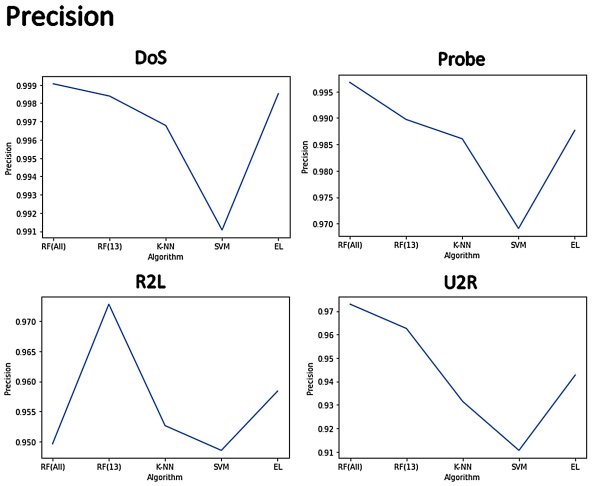

Gambar 14: Tingkat Presisi masing-masing Serangan

Tingkat sensitifitas dari masing-masing serangan disajikan dalam bentuk diagram garis seperti pada “Gambar. 15”.

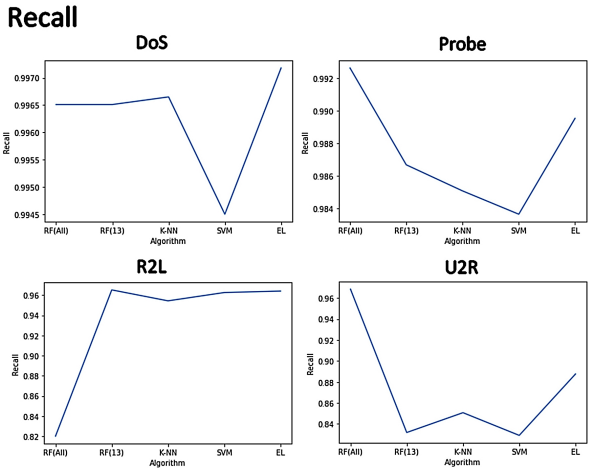

Gambar 15: Tingkat Recall masing-masing Serangan

Perbandingan rata-rata antara presisi dan sensitifitas dari masing-masing serangan disajikan dalam bentuk diagram garis seperti pada “Gambar. 16”.

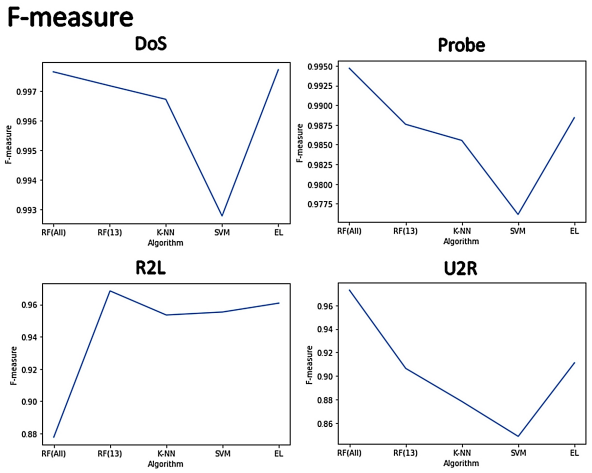

Gambar 16: F-measure masing-masing Serangan

V. KESIMPULAN

Dalam penelitian ini, kami membandingkan beberapa model untuk sistem deteksi intrusi menggunakan *Random Forest*, *K-Neighbors*, *Support Vector Machine*, dan *Ensemble Learning* dengan ketiga model diatas. Performa keempat pendekatan ini telah diamati berdasarkan *accuracy*, *precision*, *recall*, dan *f-measure* (F_1*-score*).

Dari hasil pengujian, tingkat performa dari masing-masing algoritma dipengaruhi oleh banyaknya data sampel serta berdasarkan nilai prediksi dan nilai aktual pada *Confusion Matrix* hasil klasifikasi yang dilakukan oleh sistem (model).

Dalam melakukan perbandingan performa, penelitian ini lebih memilih diprediksi diserang ternyata tidak diserang (FP) daripada diprediksi tidak diserang ternyata diserang (FN). Kemampuan klasifikasi algoritma *Ensemble Learning* menghasilkan nilai *False Negative* lebih sedikit dibandingkan algoritma lainnya, sehingga algoritma ini dinilai lebih tinggi tingkat akurasi dan ketepatan.

Hasil penelitian ini sangat berguna untuk penelitian masa depan dengan cara memaksimalkan tingkat kinerja serta meminimalkan nilai *False Negative*.

REFERENCES

[1] N. Farnaaz and M. Jabbar, “Random forest modeling for network intrusion detection system,” *Procedia Computer Science*, vol. 89, pp. 213–217, 2016.

[2] Y. Liao and R. Vemuri, “Use of k-nearest neighbor classifier for intrusion detection,” *Computers and Security*, vol. 21, pp. 439–448, 10 2002.

[3] N. Nurhadi, *Aplikasi Intelligence Intrusion Detection System (IIDS) Dengan Menggunakan Metode K-Nearest Neighbor Untuk Mendeteksi Serangan Pada Jaringan*. PhD thesis, Universitas Islam Negeri Sultan Syarif Kasim Riau, 2017.

[4] Z. Lubis, P. Sihombing, and H. Mawengkang, “Optimization of k value at the k-nn algorithm in clustering using the expectation maximization algorithm,” in *IOP Conference Series: Materials Science and Engineering*, p. 012133, IOP Publishing, 2020.

[5] M. A. Hasan, M. Nasser, B. Pal, and S. Ahmad, “Support vector machine and random forest modeling for intrusion detection system (ids),” *Journal of Intelligent Learning Systems and Applications*, vol. 06, pp. 45–52, 01 2014.

[6] E. Xydas, C. Marmaras, L. Cipcigan, A. Sani Hassan, and N. Jenkins, “Forecasting electric vehicle charging demand using support vector machines,” *Proceedings of the Universities Power Engineering Conference*, pp. 1–6, 09 2013.

[7] W. Zhang, F. Liu, L. Longqiang, and J. Zhang, “Predicting drug side effects by multi-label learning and ensemble learning,” *BMC Bioinformatics*, vol. 16, 11 2015.

[8] Mamcose, “Nsl-kdd-network-intrusion-detection,” 2019.